

Prédiction de la sévérité des symptômes moteurs dans la maladie de Parkinson à partir de variables cliniques, neuroanatomiques et métaboliques

Introduction

La maladie de Parkinson est une maladie neurodégénérative caractérisée principalement par une atteinte progressive du système moteur. La cause est essentiellement la dégénérescence des neurones dopaminergiques de la substance noire, une structure cérébrale impliquée dans le contrôle des mouvements.

Cette pathologie entraîne différents symptômes moteurs tels que des tremblements, de la rigidité musculaire, ainsi que de la lenteur dans les mouvements (bradykinésie) . La sévérité des symptômes moteurs peut différer considérablement selon les patients, ce qui suppose l'influence de multiples facteurs d'origine cliniques, neuroanatomiques ou biologiques.

De nombreuses recherches montrent que certains facteurs, comme l'âge, le sexe, les antécédents familiaux ou la présence de dépression, influencent l'évolution de la maladie de Parkinson et potentiellement l'intensité des symptômes moteurs.

Certaines structures du cerveau, telles que la substance noire et le noyau caudé, jouent aussi des rôles importants dans l'apparition et l'aggravation des symptômes moteurs. Les biomarqueurs métaboliques commencent également à occuper une place importante dans l'étude de la maladie de Parkinson, car ils pourraient refléter certaines perturbations biologiques associées à la neurodégénérescence.

Notre étude a pour objectif d'analyser l'association entre des variables cliniques, neuroanatomiques et métaboliques et la sévérité des symptômes moteurs chez des patients atteints de la maladie de Parkinson. La sévérité motrice sera évaluée à l'aide du score moteur de l'échelle UPDRS.

On se reposera sur des analyses descriptives, des tests statistiques et un modèle de régression permettant d'évaluer les relations entre les différentes variables étudiées et le score moteur UPDRS.

Problématique

Dans quelle mesure les variables cliniques, neuroanatomiques et métaboliques influencent-elles la sévérité des symptômes moteurs chez les patients atteints de la maladie de Parkinson ?

Hypothèses de travail

Les variables cliniques, neuroanatomiques et métaboliques sont associées à la sévérité des symptômes moteurs chez les patients atteints de la maladie de Parkinson.

Plus précisément, nous supposons qu'un âge plus avancé au diagnostic, la présence de dépression ou d'antécédents familiaux, ainsi qu'une diminution du volume de certaines structures cérébrales comme la substance noire et le noyau caudé, sont associés à une augmentation du score moteur UPDRS. De plus, certaines modifications des biomarqueurs métaboliques pourraient également être liées à une aggravation des symptômes moteurs. Selon de récentes études, les quantités de 4 biomarqueurs : BHB, glycine, pyruvate et sérine augmentent avec la progression de la maladie tandis que la bétaine baissait.

Variable principale étudiée : Score moteur UPDRS

Le score moteur de l'échelle UPDRS (Unified Parkinson's Disease Rating Scale) constitue la variable principale étudiée dans ce travail. Il permet d'évaluer la sévérité des symptômes moteurs chez les patients atteints de la maladie de Parkinson. Le score est classé selon différents niveaux de sévérité allant de 0 à 4. Il s'agit de la variable dépendante de l'étude et elle est considérée comme une variable quantitative discrète dans le cadre des analyses statistiques.

Variables explicatives

L'âge sera considéré ici une variable quantitative discrète, il permettra d'évaluer l'influence de l'âge sur la sévérité des symptômes moteurs.

Le sexe constitue une variable qualitative nominale, distinguant les patients de sexes masculin ou féminin sans relation d'ordre.

Les antécédents familiaux sont étudiés comme une variable qualitative binaire (présence ou absence d'antécédents familiaux de Parkinson).

La présence de dépression est également prise en compte comme variable qualitative binaire, afin d'évaluer son éventuel impact sur l'évolution de la maladie.

L'ethnicité est aussi une variable qualitative nominale, composée de plusieurs catégories sans hiérarchie particulière, permettant d'étudier d'éventuelles différences entre groupes de population.

Sur le plan neuroanatomique, le volume de la substance noire et celui du noyau caudé sont des variables quantitatives continues, mesurées à partir de données d'imagerie cérébrale.

Enfin, plusieurs biomarqueurs métaboliques sont intégrés à l'analyse, notamment le taux de BHB (β -hydroxybutyrate), de glycine, de pyruvate, de sérine et de bétaine. Ces variables

quantitatives continues permettent d'explorer l'éventuelle association entre des perturbations métaboliques et la sévérité des symptômes moteurs.

Hypothèses statistiques

Âge

H0 : L'âge n'est pas associé au score UPDRS.

H1 : Une augmentation de l'âge est associée à une augmentation du score UPDRS.

Sexe

H0 : Il n'existe pas de différence de score UPDRS selon le sexe.

H1 : Le score UPDRS diffère selon le sexe.

Antécédents familiaux

H0 : Les antécédents familiaux n'influencent pas le score UPDRS.

H1 : Les patients présentant des antécédents familiaux présentent des scores UPDRS plus élevés.

Dépression

H0 : La dépression n'est pas associée au score UPDRS.

H1 : Les patients présentant une dépression ou des antécédents de dépression ont des scores UPDRS plus élevés.

Substance noire

H0 : Le volume de la substance noire n'est pas associé au score UPDRS.

H1 : Une diminution du volume de la substance noire est associée à une augmentation du score UPDRS.

Population étudiée

L'étude porte sur un échantillon simulé de 120 patients atteints de la maladie de Parkinson.

Les données ont été générées artificiellement à l'aide du langage Python de manière à obtenir une base de données réaliste et cohérente avec les caractéristiques habituellement observées chez des patients atteints de la pathologie.

Chaque patient a été identifié à l'aide d'un identifiant unique pour une meilleure organisation des données.

Base de données et outils utilisés

Les données ont été générées dans un environnement Python (Jupyter Notebook). La base de données a ensuite été exportée au format CSV puis importée dans Excel et Access.

Les analyses statistiques, figures et graphiques ont été réalisées par la suite à l'aide de Rcmdr.

Méthodologie statistique

Une analyse descriptive des variables a d'abord été réalisée sur l'échantillon afin de résumer ses principales caractéristiques.

Les variables quantitatives, dont l'âge, les volumes neuroanatomiques, les biomarqueurs métaboliques et le score UPDRS, ont été décrites par des statistiques descriptives comme la moyenne, la médiane, l'écart-type, les valeurs minimales et maximales. Des histogrammes ont été réalisés afin de visualiser leur distribution.

Les variables qualitatives, comme le sexe, les antécédents familiaux, la dépression ou l'ethnicité, ont été étudiées avec des tableaux de fréquences et des diagrammes en barres permettant de représenter la répartition des patients dans les catégories.

Une fois les statistiques descriptives finalisées, des analyses ont été effectuées afin d'étudier les relations entre les variables explicatives et le score moteur UPDRS. Les associations avec les variables quantitatives ont été analysées à l'aide de corrélations de Pearson et de diagrammes de dispersion. Les comparaisons du score UPDRS entre deux groupes, notamment selon le sexe ou la présence d'une dépression, ont été réalisées à l'aide de tests t de Student pour échantillons indépendants et représentées en graphique par des boîtes à moustaches. L'association entre l'ethnicité et le score UPDRS a été étudiée à l'aide d'une ANOVA de variance à un facteur, complétée par des boxplots permettant de visualiser et comparer les distributions entre groupes.

Finalement, nous avons réalisé une régression linéaire multiple afin d'identifier les variables les plus significativement associées à la sévérité des symptômes moteurs. Le score UPDRS a été utilisé comme variable dépendante, avec l'ensemble des variables intégré comme variables explicatives. Ainsi, les coefficients du modèle, les p-values, le coefficient de détermination (R^2) ainsi que les variables significatives ont été obtenus puis interprétés.

Résultats

(A)

```
UPDRS
Min.   :0.000
1st Qu.:1.000
Median :2.000
Mean   :1.758
3rd Qu.:2.000
Max.   :4.000
```

(B)




Figure 1 — Statistiques descriptives du score moteur UPDRS

(1a) Statistiques descriptives du score moteur UPDRS dans l'échantillon étudié - Les paramètres descriptifs présentés incluent la moyenne, la médiane, les valeurs minimales et maximales du score moteur UPDRS.

(1b) Distribution du score moteur UPDRS - L'histogramme représente la répartition des patients selon les différents niveaux de sévérité motrice évalués par l'échelle UPDRS.

Les statistiques descriptives du score moteur UPDRS montrent une variabilité de la sévérité des symptômes moteurs parmi les patients étudiés, avec des valeurs réparties sur plusieurs niveaux de l'échelle UPDRS.




Figure 2 — Statistiques descriptives de l'âge

(2a) Statistiques descriptives de l'âge des patients - Les paramètres descriptifs incluent la moyenne, la médiane, les valeurs minimales et maximales observées.

(2b) Distribution de l'âge des patients - L'histogramme représente la répartition des patients selon leur âge.

Les statistiques descriptives de l'âge montrent une population majoritairement composée d'adultes âgés, cohérente avec l'épidémiologie de la maladie de Parkinson. Les valeurs minimales, maximales et les quartiles indiquent une dispersion modérée des âges dans l'échantillon étudié.




Figure 3 - Statistiques descriptives de la substance noire

(3a) Statistiques descriptives du volume de substance noire des patients - Les paramètres descriptifs incluent la moyenne, la médiane, les valeurs minimales et maximales observées.

(3b) Distribution du volume de substance noire des patients - L'histogramme représente la répartition des patients selon leur volume de substance noire.

La distribution du volume de la substance noire montre une variabilité entre individus modérée parmi les patients étudiés. L'histogramme présente une distribution relativement continue et globalement compatible avec une distribution proche de la loi normale.





Figure 4 - Statistiques descriptives du noyau caudé

(4a) Statistiques descriptives du volume du noyau caudé des patients - Les paramètres descriptifs incluent la moyenne, la médiane, les valeurs minimales et maximales observées.

(4b) Distribution des volumes des noyaux caudés des patients - L'histogramme représente la répartition des patients en fonction du volume de leur noyau caudé.

Les statistiques descriptives montrent une variabilité des volumes du noyau caudé entre les patients. Les quartiles et les valeurs extrêmes indiquent une dispersion modérée des mesures, sans déséquilibre majeur dans la distribution.




(D)

(C)

```

serine
Min.    :0.680
1st Qu.:1.518
Median  :1.795
Mean    :1.841
3rd Qu.:2.125
Max.    :3.280
    
```




(E)

```

betaine
Min.    :0.300
1st Qu.:0.920
Median  :1.255
Mean    :1.219
3rd Qu.:1.470
Max.    :2.380
    
```

(F)




(G)

```

glycine
Min.    :1.010
1st Qu.:2.015
Median  :2.460
Mean    :2.440
3rd Qu.:2.873
Max.    :3.910
    
```

(H)



(I)

```

BHB
Min.    :0.1000
1st Qu.:0.4775
Median  :0.7650
Mean    :0.7862
3rd Qu.:1.0425
Max.    :1.8600
    
```

(J)




Figure 5 - Statistiques descriptives des biomarqueurs métaboliques de la maladie de Parkinson

(5a, 5c, 5e, 5g, 5i) Statistiques descriptives des différents biomarqueurs métaboliques - Les paramètres descriptifs incluent la moyenne, la médiane, les valeurs minimales et maximales observées.

(5b, 5d, 5f, 5h, 5j) Distribution des quantités de biomarqueurs retrouvées chez les patients - Les histogrammes représentent la répartition des patients en fonction des quantités de biomarqueurs mesurées.

Les statistiques descriptives des biomarqueurs métaboliques montrent des profils globalement similaires pour la plupart des molécules étudiées. Le BHB, la glycine, la sérine et le pyruvate présentent des distributions continues et plutôt homogènes, avec une variabilité modérée. Ces biomarqueurs partagent donc un comportement globalement stable au sein de l'échantillon étudié.

En revanche, la bétaine se distingue par une variabilité plus importante et donc une hétérogénéité plus marquée des concentrations entre les patients.




Figure 6 - Répartitions des patients en fonction de leur sexe

Le diagramme en barres représente les effectifs des hommes et des femmes dans l'échantillon étudié.

Les effectifs indiquent une distribution équilibrée entre les hommes et les femmes. Le diagramme en barres illustre cette répartition binaire dans l'échantillon.




Figure 7 - Statistiques descriptives des antécédents familiaux - Le diagramme en barres illustre la répartition des patients avec ou sans antécédents familiaux de maladie de Parkinson.

Les statistiques descriptives montrent qu'une majorité des patients ne présente pas d'antécédents familiaux de maladie de Parkinson.




Figure 8 - Répartition des patients atteints de dépression - Les effectifs des patients dépressifs et non dépressifs sont présentés.

L'histogramme montre qu'une majorité de patients ne sont et n'ont pas été atteints de dépression.




Figure 9 - Répartition des patients selon leur ethnie

Les statistiques descriptives montrent une répartition des patients en cinq groupes ethniques. Les effectifs sont globalement équilibrés et il y a une diversité relativement homogène de la population.

ANALYSE STATISTIQUE

Dans cette partie, on vérifie nos hypothèses statistiques.

On étudie d'abord la corrélation entre l'âge et le score UPDRS. Pour cela, on utilise le test de corrélation de Pearson à l'aide de R commander. On obtient les résultats suivants :

Coefficient de corrélation (cor) : 0.375, p-value : 0.00002379, Intervalle de confiance (IDC) (95%) : [0.210 ; 0.520].

La p-value est inférieure au seuil de significativité (0.05), il y a donc bien une relation entre l'âge et le score UPDRS. Il y a une corrélation positive entre ces deux variables puisque le cor est positif. On a ici une corrélation modérée puisque le cor est compris entre 0,3 et 0,5. La borne inférieure de l'IDCe étant

positive, elle nous conforte dans l'idée d'une corrélation positive. Un âge avancé est donc associé à une augmentation du score UPDRS (H1).




Figure 10 - Diagramme de dispersion de l'âge en fonction du score UPDRS

On s'intéresse maintenant à un lien entre le sexe des patients et le score UPDRS. On utilise un test t de Welch. On obtient les valeurs suivantes :

p-value : 0.2543, moyenne du groupe des femmes : 1.65, moyenne du groupe des hommes : 1.867, IDC (95%): [-0,591; 0,158]

Les résultats indiquent qu'il n'y a pas de différence statistiquement significative ($p\text{-value} > 0,05$) entre les deux groupes. Bien que la moyenne observée dans l'échantillon soit légèrement plus élevée pour les hommes que pour les femmes, cette différence n'est pas suffisante pour être généralisée à la population, et l'IDC inclut zéro. Le score UPDRS ne varie pas significativement en fonction du sexe selon nos données (H0).




Figure 11 - Diagramme en boîte à moustaches du score UPDRS en fonction du sexe des patients

On fait le même test avec le score et la dépression. On obtient:

p-value: 0,0008, moyenne du groupe Non : 1,51, moyenne du groupe Oui : 2,15, IDC (95%) : [-1.008; -0.269]

Le test t de Welch indique une différence hautement significative (p-value < 0,05) du score UPDRS entre les patients avec dépression et ceux sans dépression . Les patients souffrant de dépression ont des scores UPDRS significativement plus élevés que les patients sans dépression (H1).




Figure 12 - Diagramme en boîtes à moustache du score UPDRS en fonction de la présence ou non de dépression chez les patients

On s'intéresse à l'ethnie des patients. L'ethnie est définie par leur continent d'origine. On utilise l'ANOVA à 1 facteur pour analyser l'impact de l'ethnie sur le score UPDRS.

Résultats: p-value: 0.974, F-value: 0.124

Groupe	Moyenne (UPDRS)	Ecart-type (sd)	Effectif (n)
Afrique	1.76	0.83	17
Amérique du Nord	1.85	0.97	26
Amérique du Sud	1.80	1.24	30
Asie	1.70	0.98	20
Europe	1.67	1.07	27

Figure 13 - Tableau de résultats de l'ANOVA à 1 facteur ethnie/UPDRS

Les résultats ne montrent aucune différence statistiquement significative (p-value >> 0,05) entre les groupes ethniques. Les moyennes observées (de 1.67 pour l'Europe à 1.85 pour l'Amérique du Nord) sont très similaires, indiquant que l'origine ethnique n'est pas associé au score UPDRS dans cette population.

On étudie maintenant la relation entre le score UPDRS et le volume de substance noire chez les patients. On utilise le test de corrélation de Pearson.

Résultats: p-value : 0.01047, cor: -0.233, IDC (95%): [-0,395; -0.056]

La p-value indique une différence statistique significative ($p\text{-value} < 0,05$). Il y a bien un lien de corrélation entre les deux variables. On a un cor négatif donc une corrélation négative. Plus le volume en substance noire est élevé, plus le score UPDRS sera bas (H1). La corrélation est cependant plutôt faible puisque le cor est compris entre -0,1 et -0,3. La substance noire n'explique donc qu'une petite partie de la variabilité du score UPDRS. L'IDC se situant dans les négatifs confirme la fiabilité de la corrélation négative.




Figure 14 - Diagramme de dispersion du volume de substance noire en fonction du score UPDRS

On applique le même traitement pour le volume du noyau caudé et la quantité de biomarqueurs par rapport au score UPDRS.

Résultats noyau caudé/UPDRS: p-value : 0.023, cor : -0.207, IDC (95%) : [-0,372;-0.029]

On a ici une différence statistique significative ($p\text{-value} < 0,05$). Il existe un lien de corrélation entre les deux variables. Le cor est inférieur à 0 la corrélation est donc négative, plus le volume du noyau caudé est bas plus le score UPDRS sera élevé. On a ici une corrélation négative faible. L'IDC corrobore cette analyse puisque ses 2 bornes sont négatives.




Figure 15 - Diagramme de dispersion du volume du noyau caudé en fonction du score UPDRS

Résultats UPDRS/biomarqueurs:

Biomarqueur	p-value	cor	IDC (95%)
Bétaïne	0.454	0.068	[-0,111;0.245]
BHB	0.613	0.046	[-0.133;0.223]
Glycine	0.420	-0.074	[-0.250;0.106]
Pyruvate	0.349	-0.086	[-0.261;0.094]
Sérine	0.038	0.189	[0.010;0.356]

Figure 16 - Tableau des résultats des test de corrélation de Pearson entre le score UPDRS et la quantité de biomarqueurs

On identifie un seul biomarqueur présentant une différence statistique significative: la sérine. C’est le seul qui présente une p-value satisfaisante. On observe un lien de corrélation positif faible (compris entre 0,1 et 0,3). La sérine a donc un rôle mineur dans la variation du score UPDRS, elle favorise son augmentation.




Figure 17 - Diagramme de dispersion de la quantité de sérine en fonction du score UPDRS

Enfin, on fait une régression linéaire multiple avec pour variable réponse le score UPDRS, les autres variables sont explicatives. On obtient alors les résultats suivants : p-value de la régression multiple : 0.0000292 r² ajusté : 0,21

Variable	Coefficient (estimate)	p-value
âge	0.0267	0.0004
Bétaïne	0.104	0.6431
BHB	0.069	0.7346
Glycine	-0.168	0.2532

Noyau caudé	-0.721	0.0116
Pyruvate	-0.100	0.7597
Sérine	0.420	0.0244
Substance noire	-1.160	0.0074

Figure 18 - Tableau de résultats de la régression linéaire multiple sur le score UPDRS

Le modèle global est significatif puisque sa p-value est inférieure à 0,001. Avec un r^2 d'une valeur de 0,21, notre modèle explique environ 21% de la variation du score UPDRS. Les variables significatives mises en évidence sont l'âge, le volume de substance noire et la quantité de sérine. Les autres variables ne disposent pas d'une p-value suffisamment basse, elles n'ont pas d'effet significatif sur la variation du score UPDRS.

Discussion

Les données utilisées dans ce travail sont simulées et ne proviennent pas de patients réels. Malgré une génération visant à reproduire des tendances proches de la réalité, elles restent arbitraires. L'échantillon n'est donc pas représentatif d'une population clinique réelle, et la variabilité biologique ainsi que les mécanismes physiopathologiques sont volontairement simplifiés.

Plusieurs biais peuvent influencer les résultats, notamment la simplification des relations entre variables, l'absence de certaines comorbidités et la réduction de la complexité des processus biologiques impliqués dans la maladie de Parkinson.

Par ailleurs, les analyses statistiques permettent uniquement de mettre en évidence des associations entre variables, sans établir de lien de causalité. Ainsi, une corrélation observée, par exemple avec la dépression et le score UPDRS, ne permet pas de conclure sur un lien direct ou un sens d'influence.

Enfin, le modèle de régression linéaire multiple présente une capacité explicative limitée du score UPDRS, suggérant que d'autres facteurs importants (traitements, stade de la maladie, durée d'évolution) ne sont pas inclus et devraient être intégrés pour améliorer la performance du modèle.

Conclusion

Cette étude a permis d'analyser l'association entre des variables cliniques, neuroanatomiques et métaboliques et la sévérité des symptômes moteurs dans un modèle simulé de la maladie de Parkinson. Les résultats montrent que certaines variables, dont l'âge et les volumes cérébraux, sont statistiquement associées au score UPDRS. Pour autant, le modèle présente une capacité explicative limitée et ne permet pas d'établir de relations causales.

Bibliographie/Webographie

[Parkinson's Disease Data Set](#)

[Datasets | Parkinson's Disease](#)

[Parkinsons - UCI Machine Learning Repository](#)

<https://rdcu.be/fh8OZ>

<https://doi.org/10.1038/s41582-026-01185-z>

<https://www.ncbi.nlm.nih.gov/pmc/articles/PMC8843749/pdf/jci-132-146400.pdf>

[Recherche d'un biomarqueur indicatif](#)